多模态神经算子技术文档

从一维 **Burgers** 原型走向可组合的多模态时空求解器

> 本文档是新版主线文档，旧版按实验编号累积的 Burgers 技术报告不再作为当前叙述。 旧结果只在需要支撑结论时引用，不再沿用旧的章节与版本号。 当前形态仍以 1D Burgers 为验证任务，但架构、数据接口和训练策略按多模态神经算子设计。

项目	内容
文档版本	新版第 10 版，2026-11-05
主程序	`code/demo_burgers_dataset.py`
当前任务	1D Burgers，周期边界，多初值族与多黏度
数据目录	`datasets/burgers_custom_v1/`
默认训练集	`burgers_custom_train_curriculum2_shift3.parquet`，4,224 条
默认优化器	AdamW，`weight_decay=1e-4`，`dropout=0.05`，流形权重衰减 0
默认学习率	`lr=7.5e-4`，**无预热**，cosine 退火 24k
文档状态	主线重写；多模态接口已落地，传感器融合仍是待解决问题

1 目标与边界

这个项目不再只追求“把 Burgers 的测试误差再压低一点”。当前目标是建立一个可组合的神经算子：

$$\mathcal{G} : (u_0,\ S,\ p,\ \mathrm{aux}) \mapsto u(x,t), \tag{1}$$

其中

- $u_0(x)$：初始场或空间观测；
- $S = \{(x_i, t_i, u_i)\}_{i=1}^{K}$：稀疏传感器观测；
- p：黏度、材料参数、工况、载荷等标量或向量条件；
- aux：文本、图像、拓扑或其它可选辅助信息；
- 输出是在任意 (x,t) 查询的解。

神经算子仍然是核心：模型学习的是从条件到函数的映射，而不是针对单个 PDE 实例重新训练。 多模态部分不改变这个目标，只改变条件如何进入模型。

当前边界必须写清楚：

1. 只在 1D Burgers 上完成了数值验证；
2. 传感器模态已接入代码，但直接融合的精度是负结果；
3. 文本和图像模态只有接口设计，没有实验结果；
4. 所有“当前最好”只适用于本文指定的数据划分与指标。

2 神经算子主干

2.1 总体结构

当前主干由三部分组成：

1. 场编码器：初始场 u_0 经高通通道、CNN tokenizer 和流形自编码器，得到局部 token 与低维潜码 z_0；
2. 时间演化：潜码通过可学习的向量场积分，得到 $z(t)$；
3. 查询解码器：在任意 (x,t) 处，用 Fourier 坐标特征、局部初始场特征和 $z(t)$ 组成查询向量，通过交叉注意力读取上下文，输出 $\hat{u}(x,t)$。

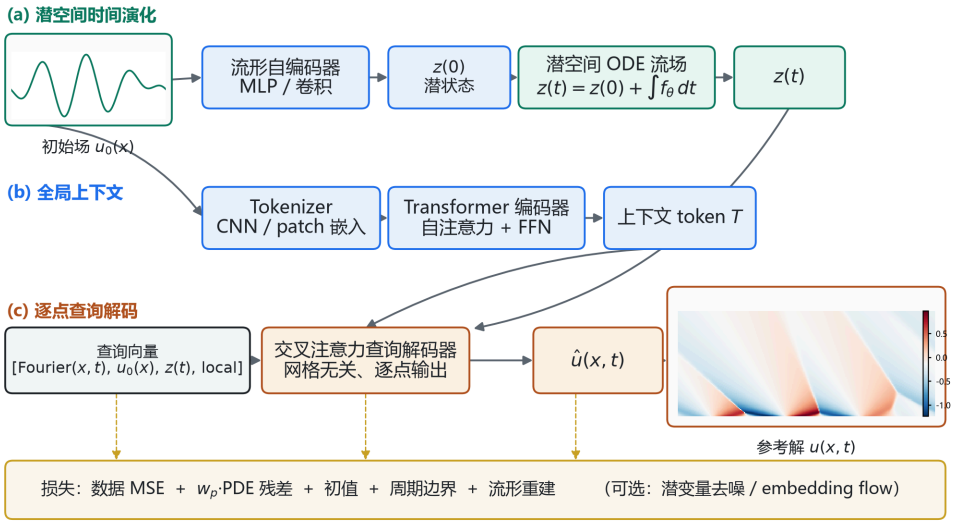


图 1 当前主干。场编码与潜空间时间演化负责“动力学”，交叉注意力负责“全局读取”，查询解码器负责任意坐标输出。

设场 token 为 T_f，上下文编码器为 Φ，则当前场分支可以写成

$$T_f = \mathrm{CNN}_{\mathrm{highpass}}(u_0), \qquad C_f = \Phi(T_f + \mathrm{pos} + \mathrm{proj}(z_0)). \tag{2}$$

查询向量为

$$q(x,t) = \mathrm{MLP}\left[\gamma(x,t),\ z(t),\ u_0^{\mathrm{local}}(x)\right], \qquad \hat{u}(x,t) = \mathrm{Dec}\left(q(x,t), C_f\right). \tag{3}$$

2.2 为什么保留神经算子

保留神经算子有三个直接原因：

1. 推理不依赖网格：训练完成后，查询坐标可以任意给定；
2. 时间演化与查询解耦：换初始条件只需重新编码，不需要重新求解整个 PDE；
3. 多模态可以挂接在条件侧：传感器、参数、文本和图像都可以作为额外上下文，而不必重写输出头。

这也是后续所有多模态改造的前提。

3 多模态统一 token 设计

3.1 统一接口

多模态部分采用一个共享的 token 空间，而不是为每种模态单独增加预测分支：

$$C = \Phi\left([T_f;\ T_s;\ T_p;\ T_a]\right), \qquad T_m \in \mathbb{R}^{n_m \times d_{\text{model}}}. \tag{4}$$

各类模态先用轻量适配器投影到 d_{model}，再加类型嵌入：

- 场 token：T_f，来自 CNN tokenizer；
- 传感器 token：T_s，由 $[x_i, t_i, u_i, \text{mask}_i]$ 经 MLP 得到；
- 参数 token：T_p，由黏度、材料参数、工况等标量/向量经 MLP 或 FiLM 得到；
- 辅助 token：T_a，文本或图像经冻结编码器后投影得到。

这样做的目的不是“堆模块”，而是让所有条件进入同一个注意力上下文，由查询解码器统一读取。

3.2 已实现的传感器接口

代码已经支持：

```
--sensor-count K
--sensor-time t
```

每个样本在 K 个固定 x 位置取测点，时间固定为 t，把 $[x, t, u]$ 投影成 token。当前实现把传感器 token 与场 token 送进同一个 Transformer， 再由查询解码器交叉注意力读取。

这个接口证明了模型可以接收第二种模态，但还不够好。首次实验的结论见第 6.5 节。

3.3 参数与辅助模态

参数模态的推荐做法是 token 化，而不是直接拼接到查询向量：

$$T_p = \text{MLP}(p) + \text{type}_p. \tag{5}$$

文本和图像不建议在 Burgers 原型里直接训练大编码器；更合理的工程路线是：

1. 用冻结的文本/图像编码器产生特征；
2. 用线性层投影到 d_{model}；
3. 加模态类型嵌入；
4. 与场、传感器 token 一起进入上下文；
5. 通过跨模态一致性损失约束语义与物理量之间的关系。

当前没有文本/图像实验，不能把这条路线写成已验证收益。

4 数据与增强

4.1 数据集

自建数据包含四个初值族和多组黏度：

- `fourier`：平滑随机 Fourier 初值；
- `mixture`：Fourier 与高斯凸起混合；
- `weak_steps`：温和台阶，用于课程训练；
- `weak_spikes` / `weak_hifreq`：温和尖峰与高频课程样本。

训练集课程-2 共 1,408 条；dev/test 各 128 条；另有三类 OOD 测试：

- 台阶 OOD；
- 尖峰 OOD；
- 高频 OOD。

4.2 严格周期平移增强

当前默认训练集为课程-2 加两个严格周期平移副本：

```
datasets/burgers_custom_v1/
  burgers_custom_train_curriculum2_shift3.parquet
```

生成脚本为 `code/make_custom_shift_augment.py`。增强只沿周期 x 方向循环滚动完整 时空场，因此

$$u'(x,t) = u(x-\delta,t) \tag{6}$$

仍是同一个 PDE 的精确解。它比“任意频谱扰动”更安全，因为它没有改变方程或解的物理结构。

训练集从 1,408 扩到 **4,224** 条；生成 4 倍增强时扩到 5,632 条，但实验证明 4 倍反而更差。

另一个数据量方案是增加独立物理轨迹，不是复制同一条轨迹：

```
code/make_custom_more.py
  -> burgers_custom_train_curriculum2_more2.parquet
  -> 2,816 条（1,408 原始 + 1,408 新求解样本）
```

这条路线用于区分“样本多样性增加”和“同一轨迹平移复制”两种不同的数据增长。

---

5 训练流程与早停

5.1 损失

当前训练包含：

- 数据点损失；
- 初始条件损失；

- 周期边界损失；
- 可选 PDE 残差损失；
- 可选潜码重建/去噪损失。

当前 Burgers 主线默认关闭物理损失（`physics-weight=0`），因为在该数据配方下，物理项 容易把优化目标带向“残差更小但场误差更大”的解。多模态阶段需要重新定义一致性损失， 而不是直接恢复旧物理权重。

5.2 早停

早停规则已经改为：

- 每 `eval_every` 步评估 dev；
- 连续 **4** 次评估没有改善即停止；
- 只有训练到预算的 **75%** 之后才开始计入早停；
- 始终保存并回滚 best dev state；
- dev 分数为相对 L_2 加验证 PDE 残差项。

对应参数：

```
--early-stop-patience 4
--early-stop-min-delta 0.0
--early-stop-min-fraction 0.75
```

旧实验为了“跑满预算”普遍传了 `--early-stop-patience 100`，这等价于不早停。 正式 seed 23 运行已经验证该策略：best-dev 在 18k，22k 时连续 4 次无改善并停止， `completed_steps=22001`，最终测试与跑满 24k 的差异在 1%–2% 内。 75% 保护阈值避免了第一次试验在 11k 过早停止的问题。

seed 23	test_id	台阶 OOD	尖峰 OOD2	高频 OOD3
跑满 24k	0.1071	0.1282	0.3007	0.3171
早停 22k	0.1081	0.1312	0.3040	0.3222
变化	+1.0%	+2.3%	+1.1%	+1.6%

短测已确认触发路径：在 512 条训练样本的 smoke 运行中令 `patience=1`， 训练在第 401 步停止（best step=200），输出 `stopped_early=True` 并回滚 best state。 这说明早停判断和权重恢复链路都已接通；正式配置仍使用 patience=4。

早停不改变 best state 的精度，它的价值是避免继续消耗算力。延长 cosine 预算并 不能替代 24k 配方；原因见第 6.4 节。

---

6 当前实证结果

6.1 3 倍周期平移增强

下表是 3 倍增强在旧基线 `dropout=0.10 + Adam` 下的三种子结果；后续默认已切换到 `AdamW 1e-4 + dropout=0.05`，切换后的取舍见第 6.7 节。

指标	1,408 条（3 seed）	4,224 条增强（3 seed）	变化
test_id	0.1065	**0.0991**	**−6.9%**
台阶 OOD	0.1366	**0.1242**	**−9.1%**
尖峰 OOD2	0.3326	**0.3054**	**−8.2%**
高频 OOD3	0.3616	**0.3225**	**−10.8%**

同分布和台阶在 3/3 个种子上改善；尖峰和高频在 2/3 个种子上改善。增强不是“换模型”，而是扩大同一物理系统的样本覆盖。

6.2 高频通道不是越强越好

高通道定义为

$$h(u_0) = u_0 - \mathrm{smooth}_{15}(u_0). \tag{7}$$

固定其他配置，只改变通道增益：

指标	无高通道（课程-2）	scale=1.0	scale=0.5
test_id	0.1061	0.1035	**0.1036**
台阶 OOD	0.1324	0.1307	**0.1317**
尖峰 OOD2	0.3196	0.3490	**0.3138**
高频 OOD3	0.3982	0.3524	**0.3458**

`scale=1.0` 会放大尖峰噪声；`scale=0.5` 保留了高频收益，同时避免尖峰退化。`scale=0.25` 只在同分布略好，OOD 不稳，因此默认取 0.5。

平滑核也有最优点：

指标	kernel=7	kernel=15	kernel=31
test_id	0.0999	**0.0998**	0.1001
尖峰 OOD2	**0.2989**	0.3011	0.3194
高频 OOD3	0.3518	**0.3344**	0.3626

`7` 只带来很小的尖峰收益，却损失高频；`31` 两项都退化。当前保留 `15`。

6.3 dropout 与增强强度

增强集下把 dropout 从 0.10 降到 0.05，双种子均值：

指标	dropout 0.10	dropout 0.05
test_id	**0.0951**	0.0954
台阶 OOD	0.1222	**0.1184**
尖峰 OOD2	**0.3078**	0.3306
高频 OOD3	**0.3252**	0.3259

降低 dropout 只改善台阶，尖峰明显变差，因此保留 0.10。

增强副本从 3 倍扩到 4 倍后，双种子均值为：

指标	3 倍（4,224）	4 倍（5,632）
test_id	**0.0951**	0.0999
台阶 OOD	**0.1222**	0.1264
尖峰 OOD2	**0.3078**	0.3370
高频 OOD3	**0.3252**	0.3378

四项全部退化，且种子波动扩大。**3** 倍是当前增强上限。

6.4 训练预算

3 倍增强下把 24k cosine 预算延到 32k，seed 11：

指标	24k	32k
test_id	**0.0925**	0.1143
台阶 OOD	**0.1200**	0.1387
尖峰 OOD2	**0.3271**	0.3611
高频 OOD3	**0.3443**	0.3608

32k 的 best-dev 提前到 18k，之后连续 14 次不改善。延长 cosine 后，同一 step 的学习率 更高，best state 反而更差。**24k** 是同调度下的拐点，不应继续延长。

6.5 传感器融合首版是负结果

给模型加入 8 个固定 x 位置、$t = 0.5$ 的测点，比较两种融合位置：

seed 11，24k	test_id	台阶 OOD	尖峰 OOD2	高频 OOD3
纯场输入	**0.0998**	**0.1269**	**0.3011**	**0.3344**
测点后拼接	0.1166	0.1431	0.3652	0.3770

seed 11，24k	test_id	台阶 OOD	尖峰 OOD2	高频 OOD3
测点前置融合	0.1173	0.1472	0.3504	0.4011

两种方式都全面退化。测点来自目标场，信息量比纯场更多，所以问题不是“缺信息”， 而是训练没有学会对齐：数据损失用带测点的上下文，物理/初始条件分支的上下文不带测点； 固定单时间切片也容易让模型记忆位置而不是学习跨模态关系。

结论：多模态接口可行，但直接拼接传感器 **token** 不是可用的融合方法。

6.6 独立新轨迹与平移增强的取舍

用两个种子比较“4,224 条平移增强”和“2,816 条独立物理样本”：

指标	4,224 条平移增强	2,816 条独立样本	变化
test_id	**0.0951**	0.1007	**+5.8%**
台阶 OOD	**0.1222**	0.1220	−0.2%
尖峰 OOD2	0.3078	**0.3032**	**−1.5%**
高频 OOD3	**0.3252**	0.3318	+2.0%

独立新轨迹并不是免费收益：它略微改善台阶和尖峰，但同分布变差 5.8%， 高频也变差 2.0%。这说明当前任务的主要瓶颈不是“独立样本数不够”， 而是数据分布和模型归纳偏置的匹配；直接增加求解样本不能替代有针对性的平移增强。 该方向保留为“尖峰优先”的可选数据配方，但不作为默认训练集。

6.7 权重衰减、AdamW 与在线平移增强

为了抑制模型记住固定增强副本，尝试了主训练 `dropout=0.05`、`weight_decay=1e-4`， 并在每个 batch 上做在线随机周期平移。结果分成两部分：

权重衰减必须用 **AdamW**。 同样 1e-4：

设置（seed 11）	test_id	说明
固定 3× 增强 + Adam L2 1e-4	0.1808	严重欠拟合，best-dev 迟迟不降
在线平移 + Adam L2 1e-4	0.1945	更差，训练轨迹被打散
固定 3× 增强 + AdamW 1e-4	**0.0878**	恢复到正常量级

Adam 的 L2 实现会对预训练流形和主网络一起施加不合适的收缩；改成 AdamW 后， 并把流形参数单独设为 0，主训练才恢复正常。当前代码支持 `--optimizer adamw --weight-decay 1e-4 --manifold-weight-decay 0`。

在线平移在当前预算下不可用。 在线平移 + AdamW 1e-4 + dropout 0.05 在 seed 11 上 best-dev 只到 16k，早停 21k，test_id 0.1170，仍明显差于固定增强。 原因在于每个 batch 都改变平移，24k 步内优化难度过高；这不是“增强无效”，而是 当前训练预算不足以吸收连续平移。

固定 3× 增强 + AdamW 1e-4 + dropout 0.05 的双种子结果是：

指标	dropout 0.10 + Adam（旧基线）	dropout 0.05 + AdamW 1e-4（新默认）
test_id	**0.0951**	0.0953
台阶 OOD	0.1222	**0.1189**
尖峰 OOD2	**0.3078**	0.3341
高频 OOD3	**0.3252**	0.3276

按当前选择，默认优化器改为 **AdamW + 1e-4 + dropout 0.05**。它改善台阶， 但尖峰 OOD 比旧基线差约 8.5%，这是已知代价。尖峰优先的任务可以回退到 `Adam + dropout 0.10`；其余任务使用当前默认。

进一步测试中间的 `dropout=0.075`（seed 11）没有得到折中收益： test_id 0.0905、台阶 0.1136、尖峰 0.3454、高频 0.3453，四项都不如 当前默认的 0.05。因此保留 `dropout=0.05`，不再继续细分 dropout。

6.8 AdamW 学习率扫描

固定 `dropout=0.05、weight_decay=1e-4、24k`，seed 11：

学习率	test_id	台阶 OOD	尖峰 OOD2	高频 OOD3
5e-4	0.0986	0.1230	**0.2890**	0.3244
7.5e-4	0.0934	0.1156	0.3261	**0.3201**
1e-3	**0.0890**	**0.1149**	0.3418	0.3425

这是一条单调取舍曲线：降低学习率改善尖峰和高频，但同分布变差； 提高学习率改善同分布和台阶，但尖峰退化。当前采用折中默认 `lr=7.5e-4`； 如果同分布优先可回到 `1e-3`，尖峰优先可降到 `5e-4`。

预热长度也做了对照（seed 11）：

warmup	test_id	台阶 OOD	尖峰 OOD2	高频 OOD3
0（当前默认）	0.0928	0.1170	**0.2971**	**0.3159**
200	0.0934	**0.1156**	0.3261	0.3201
400	0.1023	—	—	—

去掉预热后，尖峰改善 8.9%、高频改善 1.3%，同分布只差 0.6%； 400 步预热则明显退化。因此默认改为无预热、直接 **cosine** 退火。

6.9 训练效率优化（2026-11-05）

当前配方关闭物理损失（`physics_weight=0`），但原实现仍然每步采样物理点、编码物理场并计算 PDE 残差；初始条件损失又单独采样并编码另一批场。这两部分是确定性浪费。现在已改为：

1. `physics_weight=0` 时直接跳过物理分支，只保留零损失项；
2. 初始条件损失复用数据损失的 `u0/latent/context`，不再重复编码；
3. 边界损失继续复用数据上下文。

同配置、同 seed、24k 步的前后对照：

版本	训练时间	test_id	台阶 OOD	尖峰 OOD2	高频 OOD3
优化前	2170 s	**0.0928**	0.1170	0.2971	0.3159
优化后	**1733 s**	0.0940	**0.1139**	**0.2855**	**0.3134**

训练时间降低约 **20.1%**，显存不升；同分布略差 1.3%，但台阶、尖峰、高频都改善。 这说明被删掉的是无效计算，而不是有效信息。

下一步可继续压缩的计算量，按收益/风险排序：

1. **AMP（bf16/fp16）**：RTX 4060 上最可能带来大幅提速，需要加 GradScaler 并复核数值稳定性；
2. **batch size 32→64**：当前 GPU 利用率偏低，增大 batch 可提高单步吞吐，但会改变梯度噪声；
3. 降低 **dev** 评估频率或评估样本数：当前每 1000 步评估 128 条 dev 并计算 PDE 残差， 是训练时间的一部分，但会降低早停判断的粒度；
4. 用 **SDPA** 替换手工注意力：查询解码器的注意力头数固定，收益通常小于 AMP。

6.10 当前结果图

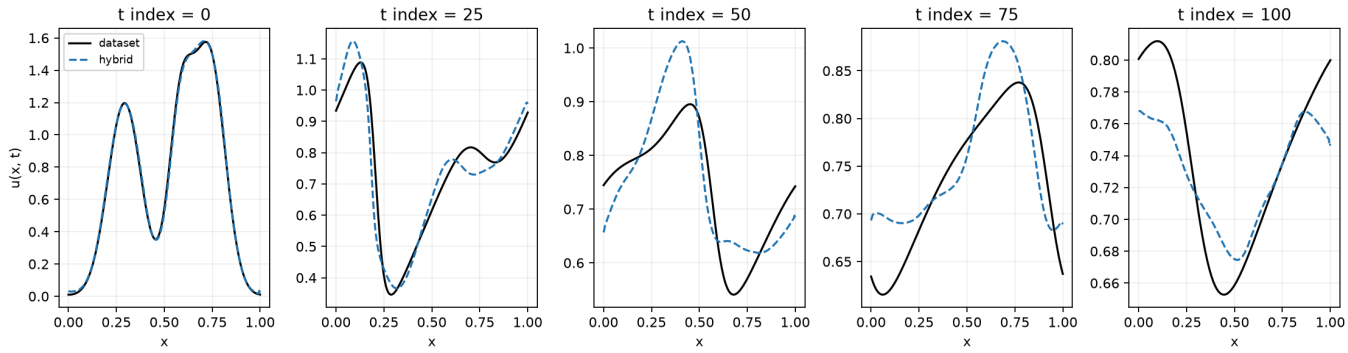


图 2 3 倍增强、seed 11 的测试预测。该模型是当前主配方的一个代表点。

7 已关闭的方向

以下方向已经有明确负结果，不再重复堆实验：

1. 任意频谱倾斜增强：分布夹生，四项退化；
2. 继续增加周期平移副本到 **4** 倍：四项退化，方差扩大；
3. 扩大 **tokenizer** 卷积核到 **7** 或 **31**：高频结构损失；
4. 把高通道增益推到 **1.0** 或 **0.25**：尖峰/高频不能同时保住；
5. 增强后降 **dropout** 到 **0.05**：尖峰退化；
6. 把 **cosine** 预算从 **24k** 拉到 **32k**：best-dev 提前，最终测试全面退化；
7. 直接把 **8** 个测点 **token** 拼接进上下文：id/OOD 全面退化。

这些负结果共同说明：当前瓶颈不是“再加一个模块”或“再堆一点同类数据”， 而是条件如何对齐、何时停止训练、以及不同物理结构需要什么归纳偏置。

---

8 多模态路线图

8.1 第一阶段：统一上下文（当前代码基础）

- 场、传感器、参数使用同一个 d_{model}；
- 加类型嵌入，避免模型把不同模态当成同一种数值；
- 所有损失分支共享同一份多模态上下文；
- 训练时随机丢弃部分模态，保证单模态也能工作。

8.2 第二阶段：跨模态一致性

多模态真正有用的关键不是“把 token 拼在一起”，而是让不同模态互相约束：

$$\mathcal{L}_{\text{align}} = \left\|\hat{u}(x_i, t_i) - u_i\right\|^2 + \left\|\hat{u}_{\text{field}} - \hat{u}_{\text{sensor-only}}\right\|^2. \tag{8}$$

第一项要求场预测解释测点，第二项要求带测点与不带测点的预测在一致区域保持一致。 再配合缺失模态 dropout，模型才不会把固定测点位置当成捷径。

8.3 第三阶段：异构模态适配

- 标量工况：token 或 FiLM；
- 时间序列：1D tokenizer；
- 文本：冻结编码器 + 投影层；
- 图像/拓扑：冻结视觉编码器 + 投影层；
- 所有模态共享类型嵌入和交叉注意力。

这条路线保留了神经算子的输出接口，同时让模型可以接收土木、医疗、交通等场景中的 异构条件。当前只完成了传感器接口，文本/图像仍是设计项。

---

9 适用性与工程限制

1. 当前精度不是工程级替代品：最好结果仍是研究原型，不能直接替代数值求解器。
2. 只在 **1D Burgers** 上验证：换方程、换维度、换边界条件都还没有证据。
3. 多模态尚无正收益：传感器首版退化，文本/图像没有实验。
4. 周期平移增强依赖周期边界：非周期问题不能直接照搬。
5. 早停只解决算力浪费：如果调度本身不合适，早停不能让 32k 变成 24k。
6. 算力代价仍高：24k 训练约 50 分钟量级，明显高于 FNO 类基线。

---

10 复现入口

当前推荐训练命令的核心参数：

```
--train-file burgers_custom_train_curriculum2_shift3.parquet
--train-samples 4224
--manifold-cnn
--input-highpass --highpass-scale 0.5 --highpass-kernel 15
--dropout 0.05
--optimizer adamw --weight-decay 0.0001 --manifold-weight-decay 0
--lr 0.00075 --warmup-steps 0
--steps 24000 --lr-decay-steps 24000
--early-stop-patience 4
```

主要文件：

- 主程序：`code/demo_burgers_dataset.py`
- 数据增强：`code/make_custom_shift_augment.py`
- 传感器评估：`code/eval_on_parquet.py`
- 技术文档：`code/TECHNICAL_REPORT.md`
- 结果目录：`experiments/outputs_burgers_dataset/`

当前推荐结果目录：

```
experiments/outputs_burgers_dataset/custom_v13_shift3_24k
experiments/outputs_burgers_dataset/custom_v13_shift3_24k_seed7
experiments/outputs_burgers_dataset/custom_v13_shift3_24k_seed23
```

---

11 结论

当前项目已经从“单一 Burgers PINN”转为“保留神经算子主干的多模态条件学习框架”：

- 神经算子主干保留，并继续作为输出层；
- 多模态接口已经能接收场和稀疏测点；
- 3 倍严格周期平移增强和 `scale=0.5` 高通道是当前最稳的单模态配方；
- 当前默认优化器为 AdamW，`weight_decay=1e-4`、`dropout=0.05`，流形预训练不参与衰减；
- 学习率采用折中 `7.5e-4`，无预热，直接 cosine 退火到 24k；
- 多模态传感器直接融合仍是负结果，下一阶段应转向共享上下文、模态 dropout 和跨模态一致性。

如果后续只能沿一个方向继续，优先做多模态对齐训练，而不是继续增加同类增强或继续堆网络模块。